1. Область применения

Распространяется на все программные модули КТК, использующие технологии искусственного интеллекта (обучение с учителем, нейросетевые модели, рекомендательные системы) для прогнозирования параметров, оценки действий оператора и адаптации сценариев.

2. Защита моделей

2.1. **Хранение** – весовые коэффициенты и архитектура моделей хранятся в зашифрованном виде (AES-256) с использованием аппаратного модуля TPM 2.0.

2.2. **Целостность** – для каждой модели вычисляется хеш-сумма (SHA-256) при развёртывании и периодически проверяется (не реже раза в сутки).

2.3. **Версионирование** – каждая версия модели подписывается электронной подписью разработчика; переход на новую версию разрешён только после успешного тестирования на изолированном стенде.

3. Защита обучающих данных

- Данные, используемые для обучения (тренировочные выборки), анонимизируются – удаляются все прямые идентификаторы пользователей.
- Применяется механизм дифференциальной приватности для снижения риска восстановления персональных данных.
- При необходимости используется федеративное обучение – модели обучаются на локальных данных, агрегируются только обновления весов.

4. Валидация входных данных

Все входные векторы, подаваемые на модель, проходят санитизацию и проверку на допустимые диапазоны для предотвращения состязательных атак (adversarial attacks). Выходные значения модели также проверяются на физическую реализуемость.

5. Изоляция выполнения

ИИ-модуль запускается в контейнере Docker с профилем AppArmor, запрещающим доступ к файловой системе хоста и сетевым интерфейсам вне разрешённых.

6. Объяснимость и логирование

- Каждое решение модели (например, рекомендация или оценка действий оператора) сохраняется в лог вместе с обоснованием (важность признаков, значения SHAP).
- Для критических оценок (принятие решения о допуске к управлению) предусмотрен режим **Human-in-the-loop** – решение принимается инструктором на основе подсказки модели.

7. Мониторинг поведения модели

- Фиксируются отклонения предсказаний от эталонных значений, а также резкие изменения весов, что может свидетельствовать о попытке отравления модели.
- Результаты мониторинга передаются в SIEM.

8. Ответственность за ИИ-компоненты

Администратор ИИ-модуля назначается из числа сотрудников, имеющих допуск к критической информации и прошедших специальную подготовку.